Programa Certified AI-LLM Solution Architect

Proyecto Final AI-LLM Solution Architect

Definiciones

Sesión 1 y Sesión 2

www.bsginstitute.com

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Leaning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data at IEBSchool – Barcelona, Spain
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialista en MLOps de la Universidad de Duke
- Estudiante de la especialización Deep Learning for Healthcare de la Universidad de Illinois

andres.rojas@triskelss.com
@arojaspa
https://www.linkedin.com/in/arojaspa/
+573005906373

PROGRAMA: AI-LLM SOLUTION ARCHITECT

Curso 5 — Proyecto Final

CAPÍTULO 1

Recolección y Análisis de Requisitos

Sesiones S1 y S2

Definiendo el Problema Correcto para la Solución AI/LLM

En AI/LLM Architecture, el error más costoso no es técnico — es construir la solución correcta para el problema equivocado.

- Caso de Uso
- Requerimientos F/NF
- Estimación
- Alcance
- Plan de Trabajo
- Riesgos

OBJETIVOS DE APRENDIZAJE

¿Qué dominarán al finalizar este capítulo?

Analizar

Descomponer un problema empresarial complejo e identificar las dimensiones técnicas y funcionales que determinan el éxito de una solución AI/LLM.

Especificar

Redactar requerimientos funcionales y no funcionales con criterios de aceptación medibles, trazables a objetivos de negocio y priorizados con rigor técnico.

Planificar

Construir una estructura de desglose del trabajo (WBS), un cronograma realista y una matriz de identificación de riesgos para el proyecto AI/LLM.

Decidir

Aplicar criterios técnicos y de negocio para seleccionar el stack tecnológico inicial y delimitar el alcance con precisión arquitectónica.

Dominio Cognitivo (Bloom): ANALIZAR — Descomponer información compleja, identificar relaciones causales y evaluar implicaciones técnicas de decisiones arquitectónicas.

El Costo de los Requerimientos Mal Definidos en AI/LLM

68%

de proyectos AI fallan por desalineación entre negocio y técnica

3.5x

mayor costo corregir un requerimiento en producción vs. diseño

40%

del tiempo de proyecto se dedica a re-trabajo por reqs ambiguos

¿Por qué importa en AI/LLM específicamente?

- Los LLMs son extremadamente sensibles al contexto del problema. Un sistema prompt diseñado para el problema equivocado es imposible de reparar sin rediseño arquitectónico.
- Las expectativas de 'magia AI' en stakeholders no técnicos son la principal fuente de fricción post-entrega. El análisis de requerimientos es gestión de expectativas.
- El costo marginal de una consulta LLM es real y acumulativo. Requerimientos de rendimiento mal definidos se convierten en facturas cloud inesperadas.
- Un vector store, pipeline RAG o agente diseñado para el caso de uso equivocado requiere re-arquitectura completa — no hay 'hot fix' viable.

Definición del Caso de Uso Empresarial

Framework: 5W+H para Casos de Uso AI/LLM

WHO — **¿Quién lo usará?**
Actor primario, secundario, sistemas integrados

WHAT — **¿Qué debe hacer?**
Capacidad central, outputs esperados

WHY — **¿Por qué AI/LLM?**
Justificación vs. solución tradicional

WHERE — **¿Dónde se despliega?**
Entorno, geografía, canal de acceso

WHEN — **¿Con qué frecuencia?**
Volumen, concurrencia, horarios pico

HOW — **¿Cómo se mide el éxito?**
KPIs cuantificables desde el día 1

AS-IS → TO-BE

SITUACIÓN ACTUAL	CON AI/LLM
✗ Proceso manual	✓ Automatizado
✗ Alta latencia	✓ < 2s respuesta
✗ Escalabilidad nula	✓ Auto-escalable
✗ Costo por FTE alto	✓ ROI positivo x3

⚡ *Regla de Oro: El caso de uso debe ser lo suficientemente específico para diseñar el system prompt, y lo suficientemente amplio para justificar la inversión arquitectónica.*

Ingeniería de Requerimientos para Sistemas AI/LLM

Anatomía de un Requerimiento Funcional Bien Escrito

RF-001 | Alta prioridad
El sistema **DEBE** recibir una consulta en lenguaje natural (≤ 2,048 tokens), recuperar los 5 fragmentos más relevantes del vector store mediante búsqueda semántica, y retornar una respuesta fundamentada en el contexto recuperado en **< 3 segundos (p95)** con una tasa de fidelidad al contexto ≥ 0.85 medida por RAGAS.

✗ Anti-patrón (Ambiguo):

"El sistema debe responder rápido y dar buenas respuestas."

✓ Bien especificado:

"El sistema DEBE procesar consultas con p95 < 2s bajo 50 usuarios concurrentes, medido con k6."

Categorías RF Específicas de AI/LLM

- **Capacidades de Inferencia**
  Tipos de consulta, idiomas, longitud de contexto
- **Gestión de Memoria**
  Historial de conversación, sesiones, ventana de contexto
- **Pipeline RAG**
  Fuentes de datos, frecuencia de indexación, top-k
- **Manejo de Casos Límite**
  Out-of-scope, ambigüedad, solicitudes maliciosas
- **Integración de Agentes**
  Herramientas disponibles, criterios de orquestación
- **Formato de Outputs**
  Estructura de respuesta, citations, confidence scores

Los RNF Determinan la Arquitectura — No Son Secundarios

Rendimiento

- Latencia p50 / p95 / p99
- Tokens por segundo
- Time to First Token (TTFT)
- Throughput (RPS)

→ *Diseño: Streaming, caching, CDN*

Escalabilidad

- Usuarios concurrentes máx.
- Estrategia de auto-scaling
- Límites de tokens/hora
- Multi-tenancy requirements

→ *Diseño: K8s HPA, rate limiting*

Seguridad

- Autenticación / Autorización
- Clasificación de datos
- Prompt injection defense
- Audit logging

→ *Diseño: Zero-trust, RBAC, guardrails*

Disponibilidad

- SLA objetivo (%)
- RTO / RPO
- Estrategia de failover
- Degraded mode behavior

→ *Diseño: Multi-AZ, circuit breakers*

Observabilidad

- Logging estructurado
- Métricas de LLM quality
- Distributed tracing
- Alerting thresholds

→ *Diseño: OpenTelemetry, Langfuse*

Cumplimiento

- Regulaciones aplicables
- Data residency
- Retención de datos
- Derechos de usuarios

→ *Diseño: Data governance, DLP*

Regla arquitectónica: Los RNF de rendimiento, escala y seguridad deben definirse ANTES de seleccionar el modelo LLM y el proveedor cloud — no después.

Delimitación del Alcance: La Decisión más Crítica del Proyecto

✅ IN SCOPE

- ✓ Interfaz de consulta vía API REST para usuarios internos
- ✓ Pipeline RAG sobre documentos corporativos (PDF, Word, DB)
- ✓ Despliegue en entorno cloud (AWS/Azure/GCP) seleccionado
- ✓ Autenticación con proveedor de identidad corporativo existente
- ✓ Dashboards de monitoreo de calidad y costo LLM
- ✓ Soporte en español e inglés únicamente

❌ OUT OF SCOPE (v1.0)

- ✗ Fine-tuning o entrenamiento de modelos desde cero
- ✗ Interfaz de usuario frontend (solo API en esta fase)
- ✗ Soporte multimodal (imágenes, audio, video)
- ✗ Integración con sistemas externos de terceros
- ✗ SLA enterprise (> 99.9%) — MVP con 99.5%
- ✗ Idiomas distintos al español e inglés

SCOPE CREEP en AI/LLM:

Añadir un nuevo tipo de fuente de datos, un idioma adicional, o capacidades multimodales durante el sprint de implementación puede duplicar la complejidad del pipeline RAG y triplicar los costos de embedding. Documente explícitamente qué NO hace el sistema v1.0.

Estimación Preliminar de Recursos y Esfuerzo

Equipo Humano

Rol / Servicio	Nivel / Tier	Estimación	Observaciones
Arquitecto AI/LLM	Senior	40-60h	Diseño, revisión técnica
ML Engineer	Mid-Senior	80-120h	Pipeline RAG, evaluación
DevOps/SRE	Mid	30-50h	IaC, CI/CD, monitoreo
Analista de Negocio	Mid	20-30h	Reqs, validación, UAT

Recursos Tecnológicos

Rol / Servicio	Nivel / Tier	Estimación	Observaciones
LLM API (OpenAI/Anthropic)	Production tier	USD $200-500/mes	Estimado 1M tokens/día
Vector Store (Pinecone/Weaviate)	Starter/Growth	USD $70-200/mes	1M vectores, 1536 dims
Cloud Compute (EKS/AKS)	2-4 vCPU, 8GB RAM	USD $150-350/mes	2 replicas mínimo
Observabilidad (Langfuse)	Cloud hosted	USD $0-50/mes	Tier gratuito disponible

Costo operacional mensual estimado MVP: USD $420 – $1,100/mes | Esfuerzo total equipo: 170 – 260 horas | Duración recomendada: 6 – 10 semanas

Estructura del Plan de Trabajo — WBS y Cronograma

Metodología recomendada: Híbrida Agile-Waterfall. Sprint de 1 semana para implementación con gate reviews en cada milestone. Uso de GitHub Projects o Jira para tracking.

Criterios de Selección Tecnológica — Marco de Decisión

Modelo/Plataforma	Rendimiento (Latencia/Throughput)	Costo Total (TCO 12 meses)	Ecosistema (Integraciones)	Madurez (Producción-ready)	Seguridad (Compliance)	Developer Experience
OpenAI GPT-4o	★★★★★	★★★☆☆	★★★★★	★★★★★	★★★★☆	★★★★★
Anthropic Claude 3	★★★★★	★★★☆☆	★★★★☆	★★★★★	★★★★★	★★★★☆
Llama 3 (Self-hosted)	★★★★☆	★★★★★	★★★☆☆	★★★☆☆	★★★★★	★★★☆☆
Gemini 1.5 Pro	★★★★☆	★★★★☆	★★★★☆	★★★★☆	★★★★☆	★★★★☆

Esta selección inicial es un punto de partida. Los ADR (Architecture Decision Records) del Capítulo 2 documentarán formalmente cada decisión con sus trade-offs.

Frameworks de Orquestación LLM:

LangChain

Ecosistema más maduro. Ideal para RAG, chains y agentes.

LlamaIndex

Especializado en RAG y recuperación de datos.

Semantic Kernel

Microsoft. Ideal para entornos .NET/Azure.

Matriz de Riesgos Iniciales del Proyecto AI/LLM

Baja — PROBABILIDAD → — Alta

MONITOREAR

R6

MITIGAR

R2

R1

R3

ACEPTAR

R7

EVITAR / ESCALAR

R4

R5

R1: Alucinaciones | R2: Costo LLM | R3: Latencia | R4: Prompt Injection | R5: Data Leakage | R6: Datos RAG | R7: Rotación equipo

ENTREGABLES CAPÍTULO 1

Entregables Requeridos — Sesiones S1 y S2

Documento de Alcance del Proyecto

Definición precisa del caso de uso empresarial (5W+H), tabla IN/OUT SCOPE, lista de requerimientos funcionales (RF-001...RF-N) con criterios de aceptación medibles, y requerimientos no funcionales con umbrales cuantificados.

20% nota cap.

Lista de Requerimientos Técnicos y Funcionales

Tabla completa de RF y RNF priorizados (MoSCoW o numérico), con ID único, descripción sin ambigüedad, criterio de aceptación, y mapeo a objetivo de negocio. Formato: Sección 2 de la Plantilla Oficial.

15% nota cap.

Plan de Trabajo + Cronograma

WBS con entregables por semana, cronograma Gantt con milestones y dependencias, asignación de roles/horas, estimación de costo operacional mensual, y selección inicial documentada de tecnologías con justificación.

15% nota cap.

Todos los entregables se suben al repositorio Git del proyecto. La fecha límite es antes del inicio del Capítulo 2 (S3). Entregables tardíos aplican penalización del 20%.

ACTIVIDAD PRÁCTICA EN CLASE

Análisis de Caso Real en Vivo — 45 minutos

📋 Escenario del Caso

Una empresa de servicios financieros (500 empleados, operaciones en 3 países) recibe 2,000 consultas diarias de clientes sobre productos de inversión, seguros y crédito a través de su call center. El 65% de las consultas son repetitivas y los agentes dedican 40% de su tiempo buscando información en 15 documentos de política diferentes (PDF, Word, SharePoint). La empresa quiere implementar una solución AI que asista a los agentes en tiempo real.

1 — 10 min — Aplicar 5W+H

Definan el caso de uso usando el framework. ¿Quién? ¿Qué exactamente hace el sistema? ¿Por qué AI/LLM y no RPA o búsqueda clásica? ¿Cuáles son las restricciones regulatorias (GDPR, secreto bancario)?

2 — 15 min — Escribir RF y RNF

Redacten mínimo 5 RF y 4 RNF con criterios de aceptación medibles. Atención especial: ¿Cuál es el SLA aceptable? ¿Los agentes pueden ver las fuentes de los datos? ¿Qué pasa si el sistema está caído?

3 — 10 min — Definir alcance

Construyan la tabla IN/OUT SCOPE para la versión 1.0. Consideren: idiomas, canales (solo agentes vs. clientes directos), tipos de documentos, horario de disponibilidad, cumplimiento con regulación financiera local.

4 — 10 min — Presentar y debatir

Cada equipo presenta su alcance y sus RNF más críticos. El instructor facilita el debate sobre decisiones de trade-off: ¿Latencia vs. Costo? ¿Precisión vs. Cobertura? ¿Seguridad vs. Usabilidad?

CONCEPTOS CLAVE

Conceptos Fundamentales del Capítulo 1

Caso de Uso AI/LLM

Descripción precisa de un problema empresarial específico, los actores involucrados, el flujo de trabajo AS-IS y TO-BE, y los criterios de éxito cuantificados. Es la base de toda decisión arquitectónica posterior.

Requerimiento Funcional (RF)

Especificación de UNA capacidad observable del sistema usando verbos modales (DEBE, PUEDE, NO DEBE) con criterio de aceptación medible. Ambiguedad cero es el estándar.

Requerimiento No Funcional (RNF)

Restricción de calidad que aplica transversalmente: latencia, escalabilidad, seguridad, disponibilidad. Determina la arquitectura y el stack tecnológico antes que cualquier RF.

Delimitación de Alcance

Definición explícita y documentada de qué está IN SCOPE y OUT OF SCOPE para una versión específica. Gestiona expectativas y previene scope creep durante la implementación.

Estimación de Esfuerzo

Proyección calibrada de horas/persona, costo operacional (cloud + APIs), y duración del proyecto basada en la complejidad de los RF/RNF identificados y la madurez del equipo.

Registro de Riesgos

Inventario inicial de amenazas al proyecto clasificadas por probabilidad e impacto, con estrategia de respuesta (mitigar, aceptar, evitar, transferir) y owner responsable.

Referencia académica: IEEE 29148:2018 — Systems and Software Engineering: Life Cycle Processes — Requirements Engineering

¿Qué aprendiste en el Capítulo 1?

Analizar casos de uso

Escribir RF/RNF sin ambigüedad

Delimitar alcance v1.0

Estimar recursos y riesgos

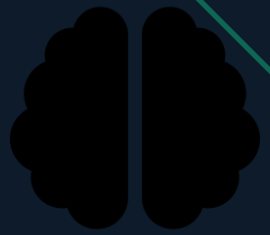

PRÓXIMO: Capítulo 2 — Diseño de la Arquitectura AI/LLM › Selección de tecnologías, diagramas C4, APIs, seguridad y plan de integración