BSG Institute

# Programa Certified Python Data Engineer

**Proyectos de Ingeniería de Datos**

Fundamentos y aplicaciones avanzadas con herramientas modernas

Sesión 1

www.bsginstitute.com

BSG Institute

# Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Leaning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data at IEBSchool – Barcelona, Spain
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialización en MLOps de la Universidad de Duke
- Estudiante de la especialización Deep Learning for Healthcare de la Universidad de Illinois

andres.rojas@triskelss.com
@arojaspa
https://www.linkedin.com/in/arojaspa/
+573005906373

# Implementación de un pipeline de datos simple

# Objetivo de la sesión:

**Comprender y e implementar un pipeline de datos funcional en Python**, integrando múltiples fuentes, aplicando operaciones de ETL y almacenando los datos en la nube, **siguiendo prácticas reales de ingeniería de datos**, con foco en **modularidad, reproducibilidad y optimización básica**. Esta sesión marca el paso **de la arquitectura conceptual a la ejecución técnica controlada**.

# Contexto de la sesión

**¿Por qué esta sesión es clave en un curso de nivel maestría?**

En la industria, **la mayoría de los pipelines de datos no son complejos por el volumen**, sino por:

- La integración de múltiples fuentes
- La necesidad de confiabilidad
- La presión por entregar valor rápido
- La obligación de operar en la nube

Por ello, antes de abordar pipelines avanzados (CDC, streaming, orquestación compleja), todo Data Engineer debe dominar **la construcción de un pipeline simple, pero correcto**.

Esta sesión se enfoca en ese principio fundamental:
*Un pipeline simple, bien diseñado, es preferible a uno complejo, frágil e inmantenible.*

# Del diseño lógico a la implementación real

# Stack mínimo esperado

En la sesión anterior se definió **cómo se diseña un pipeline** desde el punto de vista arquitectónico.

En esta sesión se responde a la pregunta:

**¿Cómo se traduce ese diseño en código Python ejecutable y portable?**

El estudiante verá cómo:

- El diseño por capas (Extract → Transform → Load) se refleja en módulos de código.
- Las decisiones arquitectónicas se convierten en responsabilidades claras.
- Un pipeline puede ejecutarse localmente y terminar en la nube sin cambiar su lógica.

Esta sesión introduce el **primer pipeline end-to-end real del curso**.

# Implementación de un pipeline ETL en Python

# 3.1 Principios que guían la implementación

La implementación del pipeline en esta sesión sigue principios profesionales:

- **Separación de responsabilidades**
  Extract no transforma, Transform no carga, Load no decide lógica de negocio.
- **Código desacoplado y configurable**
  El pipeline no depende de una nube específica ni de una fuente rígida.
- **Reproducibilidad**
  El pipeline puede ejecutarse múltiples veces con el mismo resultado (idempotencia básica).
- **Preparación para escalar**
  Aunque es un pipeline simple, su estructura permite evolucionar a pipelines más complejos.

# 3.2 Integración de múltiples fuentes

Por ello, el pipeline:

- Integra al menos dos fuentes heterogéneas
- Unifica esquemas y semántica
- Produce un dataset curado consistente

Se enfatiza que:

- Un pipeline real **nunca consume una sola fuente**
- Cada fuente tiene sus propios riesgos (errores, esquemas, latencias)

# Almacenamiento de datos transformados en la nube

# 4.1 El almacenamiento como parte del diseño, no como un detalle final

## En proyectos reales:

- El destino de los datos define su forma
- No se almacena “por almacenar”
- El formato, la partición y la ubicación importan

## Esta sesión introduce formalmente:

- **Almacenamiento en la nube como destino final del pipeline**
- Uso de **object storage** como estándar de la industria

# 4.2 Enfoque multi-cloud (conceptual)

Sin entrar aún en detalles profundos de cada proveedor, el estudiante entiende que:

- AWS, GCP y Azure resuelven el mismo problema con servicios equivalentes
- El pipeline debe ser **portable**
- El proveedor se selecciona por configuración, no por lógica de negocio

Esto prepara al estudiante para:

- Proyectos empresariales reales
- Entornos híbridos o multi-cloud
- Entrevistas técnicas de Data Engineering

# 4.3 Setup mínimo obligatorio

- **Identidad y acceso**
- Cuenta cloud activa
- Usuario IAM (no root)
- Credenciales programáticas

# Introducción a la optimización básica de pipelines

# ¿Por qué hablar de optimización desde un pipeline simple?

Porque en la práctica:

- Un pipeline ineficiente escala mal
- Los costos crecen rápido en la nube
- La latencia afecta SLAs aguas abajo

En esta sesión se introducen **conceptos básicos**, no avanzados aún:

- Optimización de transformaciones
- Uso de formatos eficientes
- Reducción de I/O innecesario
- Escritura orientada a consumo analítico

El objetivo no es micro-optimizar, sino **formar criterio técnico temprano**.

# Rol de esta sesión dentro del curso

# Esta sesión cumple tres funciones fundamentales:

**Primer pipeline real del curso**
A partir de aquí, todos los conceptos se construyen sobre este baseline.

**Validación de competencias técnicas mínimas**
El estudiante demuestra que puede pasar del diseño a la ejecución.

**Base para sesiones avanzadas**
Orquestación, CDC, calidad avanzada, streaming y optimización profunda se apoyan en este modelo.

# Resultado esperado al finalizar la sesión

# Al finalizar la Sesión de hoy

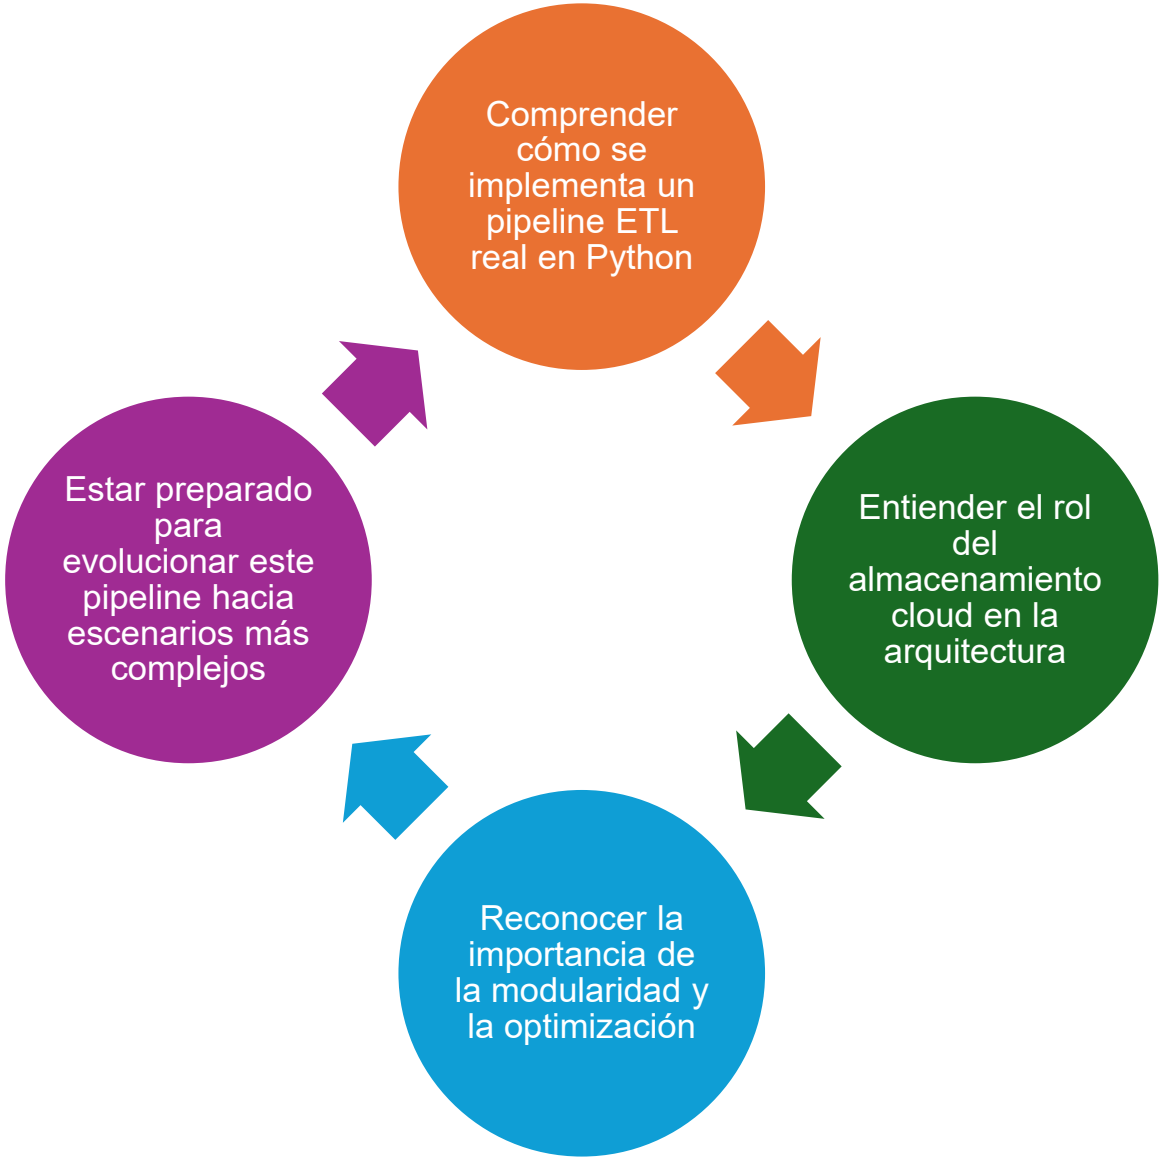

# Hands on Lab

**Con este marco conceptual claro, estamos listo para:**

- Implementar el pipeline paso a paso
- Ejecutarlo localmente
- Persistir los resultados en la nube
- Analizar decisiones técnicas y trade-offs

BSG Institute

Av. Alfredo Benavides 768, Miraflores – Lima
Urb. León XIII Calle 2 Nª 107, Cayma – Arequipa
Carrera 45 #108-27 Torre 1 Oficina 1008 – Bogotá
Av. Marcelo Terceros Bánzer 304 (3er anillo externo) – Santa Cruz
Montecito N° 38, Piso 33 of. 4 Col. Nápoles, World Trade Center – Ciudad de México

www.bsginstitute.com