BSG Institute

Programa Certified Python Data Engineer

Proyectos de Ingeniería de Datos

Fundamentos y aplicaciones avanzadas con herramientas modernas

Sesión 3

www.bsginstitute.com

BSG Institute

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Leaning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data at IEBSchool – Barcelona, Spain
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialización en MLOps de la Universidad de Duke
- Estudiante de la especialización Deep Learning for Healthcare de la Universidad de Illinois

andres.rojas@triskelss.com
@arojaspa
https://www.linkedin.com/in/arojaspa/
+573005906373

Planificación y diseño del proyecto final

Objetivo de la sesión:

Ser capaz de diseñar de forma estructurada un pipeline de datos completo, desde la ingesta hasta el almacenamiento en la nube, **tomando decisiones técnicas justificadas** sobre arquitectura, herramientas cloud y etapas ETL, como lo haría un **Data Engineer senior en un entorno empresarial real**.

Esta sesión **no se centra en escribir código**, sino en **pensar correctamente el sistema antes de construirlo**.

Contexto de la sesión

¿Por qué la planificación es crítica en un proyecto final de ingeniería de datos?

En proyectos reales de ingeniería de datos, **la mayor parte de los fracasos no se deben a errores de código**, sino a:

- Diseños incompletos o mal planteados
- Selección incorrecta de servicios cloud
- Falta de claridad en los flujos de datos
- Subestimación de escalabilidad y costos
- Ausencia de automatización desde el inicio

En un contexto académico de maestría, el **proyecto final no evalúa solo si el pipeline "funciona"**, sino si:

- Está bien diseñado
- Es coherente con el caso de uso
- Es escalable y mantenible
- Podría llevarse a producción con ajustes razonables

Esta sesión los introduce formalmente en el **rol de arquitecto de su propio proyecto**.

BSG Institute

El proyecto final como simulación de un escenario profesional

El proyecto final de este curso debe entenderse como:

“Una simulación controlada de un proyecto real de ingeniería de datos en la industria.”

Esto implica que el estudiante debe asumir responsabilidades como:

- Diseñar la arquitectura end-to-end
- Elegir servicios cloud adecuados (no arbitrarios)
- Definir claramente las etapas del pipeline
- Justificar decisiones técnicas

A partir de esta sesión:

- El estudiante deja de seguir instrucciones paso a paso
- Comienza a **tomar decisiones técnicas propias**
- Asume un rol activo como **responsable del sistema**

Diseño detallado de un pipeline completo de datos

3.1 Pensar el pipeline como un sistema completo

Un pipeline completo incluye, como mínimo:

- Fuentes de datos claramente identificadas
- Mecanismos de extracción confiables
- Transformaciones bien definidas
- Un destino final en la nube
- Consideraciones de automatización y escalabilidad

En esta sesión se refuerza que:

- El pipeline debe verse como un **flujo continuo**
- Cada etapa tiene un propósito específico
- Las decisiones en una etapa afectan a todas las demás

3.2 Diseño independiente del proveedor cloud

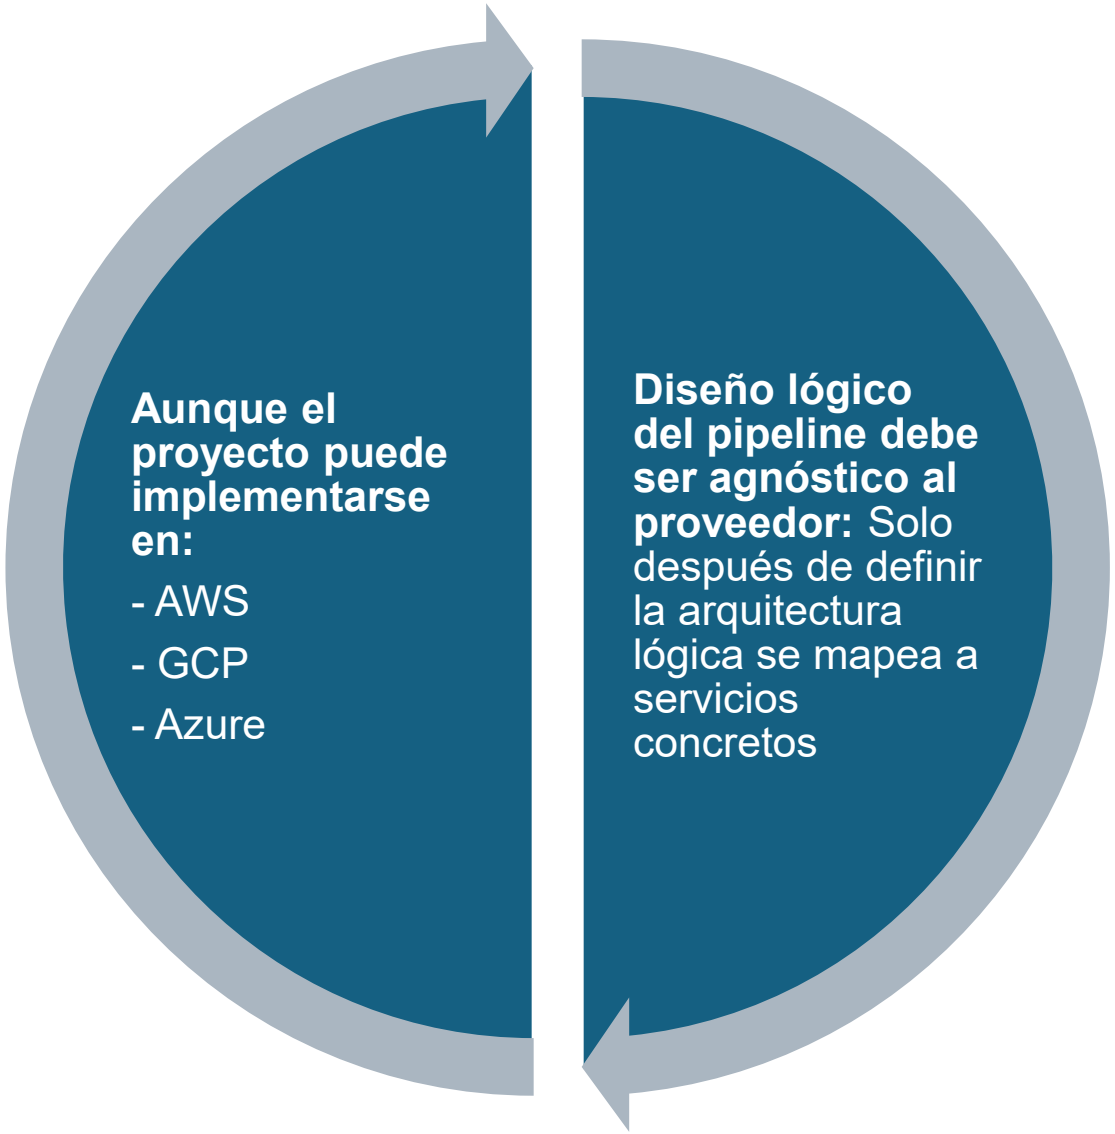

BSG Institute

Selección de herramientas y servicios en la nube

4.1 La selección de servicios como decisión de ingeniería

Elegir servicios cloud no es un ejercicio mecánico, sino una decisión de ingeniería que debe considerar

- Tipo de carga (batch, incremental, streaming)
- Volumen de datos
- Frecuencia de ejecución
- Costos
- Facilidad de operación

En esta sesión se guía al estudiante para que:

- **Comprenda el rol de cada servicio**
- Evite sobre-ingeniería
- Justifique por qué usa un servicio y no otro

4.2 Enfoque comparativo

El estudiante aprende a razonar en términos de equivalencias:

- Object storage
- Servicios de procesamiento
- Servicios de orquestación
- Servicios de monitoreo

El objetivo no es memorizar servicios qué problema resuelven

Definición de las etapas ETL del proyecto

5.1 Extracción (Extract)

El estudiante debe definir:

- Qué datos se extraen
- Desde dónde
- Con qué frecuencia
- Bajo qué condiciones de error

Se refuerza que:

- La extracción debe ser resiliente
- Debe tolerar fallos parciales
- No debe mezclar lógica de transformación

5.2 Transformación (Transform)

En esta etapa se define:

- Qué significa “datos correctos” para el proyecto
- Qué limpiezas y normalizaciones se aplican
- Cómo se garantiza consistencia

Se introduce el concepto de:

- Dataset curado
- Calidad mínima aceptable
- Preparación para consumo analítico o downstream

5.3 Carga (Load)

El estudiante define:

- Dónde se almacenan los datos finales
- En qué formato
- Con qué partición
- Para qué tipo de consumo futuro

Se enfatiza que:

- El almacenamiento no es solo persistencia
- Es una decisión estratégica del pipeline

Rol de la automatización y la optimización en el proyecto final

Aunque la implementación vendrá después, esta sesión introduce dos ideas clave:

Automatización

- Un pipeline manual no es un pipeline profesional
- El diseño debe contemplar ejecución recurrente
- La orquestación debe ser posible, aunque sea simple

Optimización

- El pipeline debe ser razonablemente eficiente
- Las decisiones de formato y estructura importan
- La escalabilidad debe estar considerada desde el diseño

El objetivo es que el estudiante piense en producción, aunque esté en un entorno académico.

Resultado esperado al finalizar la sesión

Al finalizar la Sesión de hoy

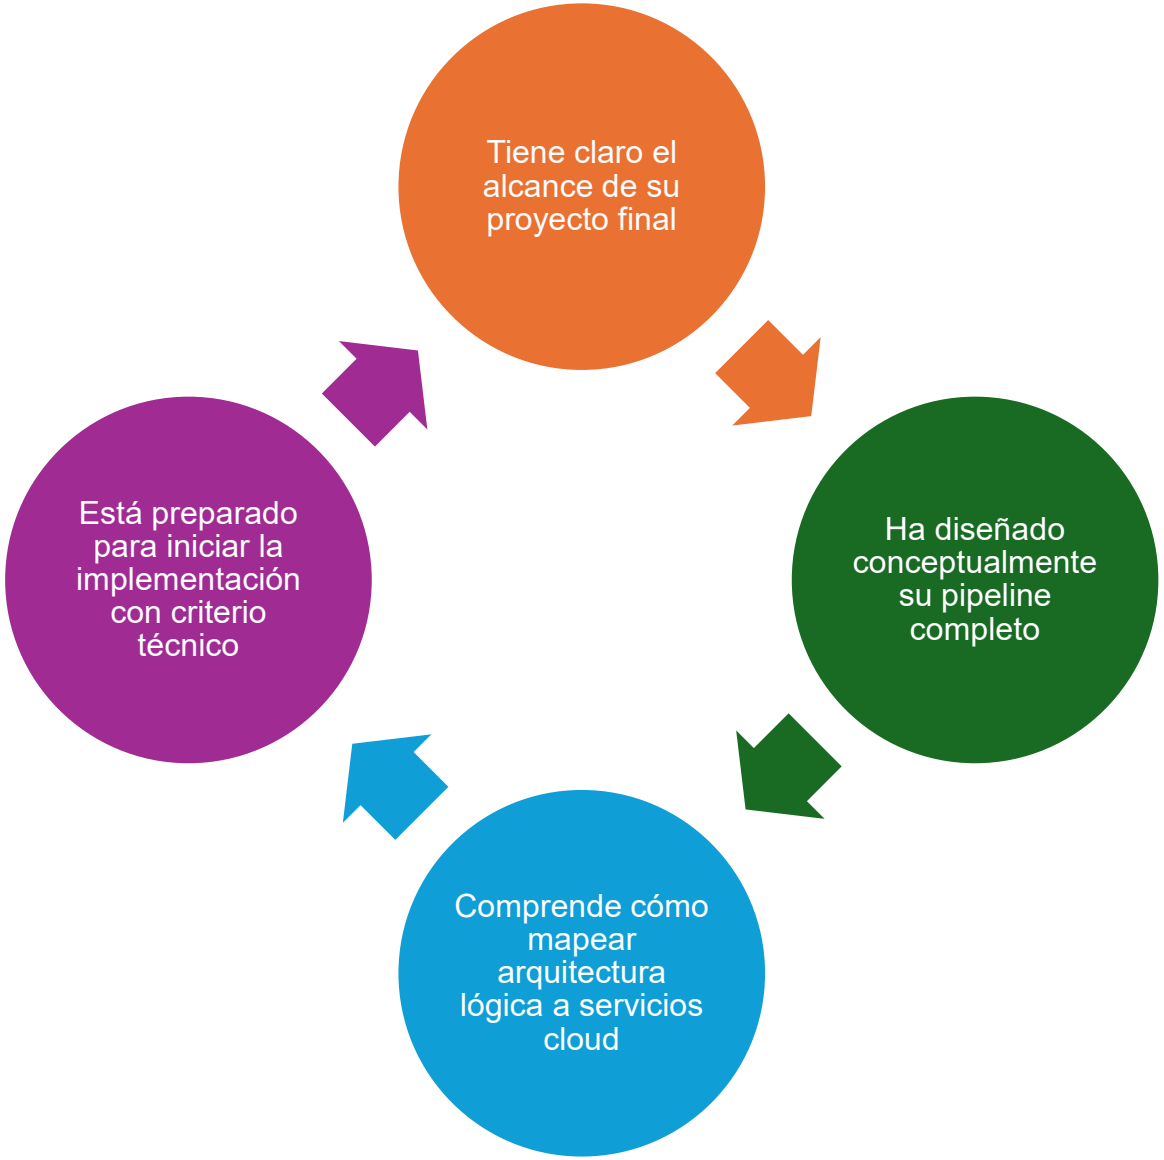

Hands on Lab

Con este marco conceptual claro, estamos listo para:

- Formalizar el diseño del pipeline
- Documentar su arquitectura
- Comenzar la implementación incremental del proyecto final

BSG Institute

Av. Alfredo Benavides 768, Miraflores – Lima
Urb. León XIII Calle 2 Nª 107, Cayma – Arequipa
Carrera 45 #108-27 Torre 1 Oficina 1008 – Bogotá
Av. Marcelo Terceros Bánzer 304 (3er anillo externo) – Santa Cruz
Montecito N° 38, Piso 33 of. 4 Col. Nápoles, World Trade Center – Ciudad de México

www.bsginstitute.com