BSG Institute

Programa Certified Python Data Engineer

Proyectos de Ingeniería de Datos

Fundamentos y aplicaciones avanzadas con herramientas modernas

Sesión 4

www.bsginstitute.com

BSG Institute

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Leaning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data at IEBSchool – Barcelona, Spain
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialización en MLOps de la Universidad de Duke
- Estudiante de la especialización Deep Learning for Healthcare de la Universidad de Illinois

andres.rojas@triskelss.com
@arojaspa
https://www.linkedin.com/in/arojaspa/
+573005906373

Desarrollo e implementación del pipeline

Objetivo de la sesión:

Implementar de forma efectiva el pipeline de datos diseñado previamente, desarrollando las etapas de extracción y transformación en Python, integrando múltiples fuentes de datos y almacenando los resultados en la nube, **aplicando principios reales de automatización, optimización y escalabilidad**.

Esta sesión marca el paso definitivo **del diseño a la construcción del sistema**.

Contexto de la sesión

¿Por qué esta sesión es crítica en el proyecto final?

En proyectos reales de ingeniería de datos, **la calidad del diseño solo se valida cuando se implementa**.

Muchas arquitecturas bien planteadas fallan al momento de:

- Integrar fuentes reales
- Manejar errores
- Escalar mínimamente
- Operar de forma repetible

Esta sesión representa:

- **El primer punto donde el proyecto final se convierte en un sistema funcional.**

Aquí se evidencian:

- La solidez del diseño realizado en la Sesión 2.1
- La capacidad del estudiante para traducir arquitectura en código
- El nivel real de competencia en ingeniería de datos

De la planificación a la implementación real

De la planificación a la implementación real

En la sesión anterior, se:

- Definió arquitectura
- Seleccionó servicios cloud
- Delimitó las etapas del pipeline

En esta sesión:

- Esas decisiones se materializan en código
- El pipeline comienza a ejecutarse de forma end-to-end
- Se identifican fricciones reales de integración

El énfasis no está en “hacer que funcione a cualquier costo”, sino en **implementar de forma limpia, modular y sostenible**.

Implementación de las etapas de extracción

3.1 Extracción como capa independiente

Se refuerza un principio clave:

- **La extracción no transforma datos.**

En esta etapa, se debe:

- Implementar conectores a fuentes reales
- Manejar fallos transitorios
- Registrar eventos relevantes
- Mantener los datos lo más crudos posible

Se enfatiza que una mala extracción:

- Contamina todo el pipeline
- Dificulta la trazabilidad
- Complica la recuperación ante fallos

Implementación de las etapas de transformación

4.1 Transformar con criterio de ingeniería

La transformación es donde el pipeline **agrega valor real**. En esta sesión se enfatiza:

- Tipado explícito
- Normalización consistente
- Deduplicación determinística
- Preparación de datasets curados

En esta sesión se guía al estudiante para entender que:

- Transformar no es “limpiar por limpiar”
- Cada transformación debe tener un propósito
- Las reglas aplicadas deben ser defendibles

Integración de múltiples fuentes de datos

5 Integración de múltiples fuentes de datos

¿Por qué la integración es uno de los puntos más complejos?

Porque:
- Las fuentes no están sincronizadas
- Los esquemas no coinciden
- Los datos pueden ser inconsistentes

Esta sesión introduce:
- Integración controlada
- Orden lógico de aplicación de transformaciones
- Manejo explícito de dependencias entre fuentes

Se refuerza la idea de que:
- **Un pipeline real integra datos, no solo los concatena.**

Almacenamiento de datos en la nube

6.1 Almacenamiento como parte del pipeline, no como un “output”

Se enfatiza que:

- El almacenamiento define cómo se consumen los datos
- El formato y la partición impactan costos y rendimiento
- La nube es el entorno natural del pipeline

El estudiante:

- Almacena datos en object storage (S3 / GCS / ADLS)
- Utiliza formatos eficientes
- Prepara los datos para consumo posterior

No se evalúa solo que los datos estén en la nube, sino **cómo están almacenados**.

Automatización y optimización inicial

Automatización y optimización inicial

Aunque el pipeline aún es básico, esta sesión introduce prácticas fundamentales:

Automatización

- Punto único de ejecución
- Configuración externa
- Preparación para ejecución recurrente

Optimización

- Evitar operaciones innecesarias
- Uso de formatos adecuados
- Separación de I/O y compute

El objetivo es formar el hábito de **pensar en producción desde el inicio**.

Rol de esta sesión dentro del proyecto final

Rol de esta sesión dentro del proyecto final

Esta sesión:

- Convierte el diseño en un pipeline funcional
- Establece el baseline técnico del proyecto
- Permite detectar problemas temprano
- Prepara el camino para automatización avanzada y optimización

A partir de aquí:

- El proyecto ya no es teórico
- Las decisiones técnicas tienen consecuencias reales
- El enfoque se desplaza hacia robustez y escalabilidad

Resultado esperado al finalizar la sesión

Al finalizar la Sesión de hoy

Hands on Lab

BSG Institute

Av. Alfredo Benavides 768, Miraflores – Lima
Urb. León XIII Calle 2 Nª 107, Cayma – Arequipa
Carrera 45 #108-27 Torre 1 Oficina 1008 – Bogotá
Av. Marcelo Terceros Bánzer 304 (3er anillo externo) – Santa Cruz
Montecito N° 38, Piso 33 of. 4 Col. Nápoles, World Trade Center – Ciudad de México

www.bsginstitute.com