BSG Institute

Programa Certified Python Data Engineer

Proyectos de Ingeniería de Datos

Fundamentos y aplicaciones avanzadas con herramientas modernas

Sesión 4

www.bsginstitute.com

BSG Institute

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Leaning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data at IEBSchool – Barcelona, Spain
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialización en MLOps de la Universidad de Duke
- Estudiante de la especialización Deep Learning for Healthcare de la Universidad de Illinois

andres.rojas@triskelss.com
@arojaspa
https://www.linkedin.com/in/arojaspa/
+573005906373

Optimización y automatización del pipeline

Objetivo de la sesión:

Que el estudiante **optimice y automatice el pipeline de datos desarrollado**, incorporando mecanismos de ejecución automática mediante servicios serverless en la nube, mejorando el rendimiento y la escalabilidad del sistema, y **defendiendo de forma técnica y argumentada las decisiones de diseño y optimización adoptadas**.

Esta sesión consolida el proyecto final como un **sistema cercano a producción**.

Contexto de la sesión

¿Por qué esta sesión es crítica en un proyecto final de Ingeniería de Datos?

En la industria, **un pipeline que funciona, pero no está automatizado ni optimizado no es un pipeline productivo**.

Muchos proyectos fallan no porque:

- El ETL esté mal implementado

Sino porque:

- Dependen de ejecución manual
- Escalan mal
- Generan costos innecesarios
- Carecen de observabilidad

Esta sesión aborda precisamente ese punto de inflexión:
La diferencia entre un pipeline académico y un pipeline profesional.

Aquí el estudiante deja de pensar solo en *"que corra"* y empieza a pensar en:

- Ejecución recurrente
- Uso eficiente de recursos
- Comportamiento bajo crecimiento
- Preparación para operación continua

De pipeline funcional a pipeline operable

De pipeline funcional a pipeline operable

Hasta la sesión anterior:

- El pipeline ya existe
- Integra múltiples fuentes
- Almacena datos en la nube

En esta sesión:

- Se convierte en un **proceso automatizado**
- Se evalúa su comportamiento bajo carga
- Se identifican cuellos de botella
- Se ajusta para mejorar desempeño y escalabilidad

Este es el paso natural que ocurre en cualquier equipo real de datos **antes de llevar un pipeline a producción**.

Automatización del pipeline con servicios serverless

3.1 Automatización como requisito profesional

Se refuerza un principio clave:

Un pipeline que depende de ejecución manual no escala ni es confiable.

En esta sesión se introduce el uso de **servicios serverless** para:

- Desencadenar ejecuciones
- Ejecutar lógica del pipeline
- Integrarse con almacenamiento y eventos cloud

El foco conceptual está en:

- Cuándo usar funciones serverless
- Qué partes del pipeline automatizar
- Qué responsabilidades delegar a la nube

No se busca complejidad innecesaria, sino **automatización pragmática**.

Optimización de escalabilidad y rendimiento

4.1 Optimizar no es “hacerlo más rápido”, es hacerlo sostenible

El estudiante aprende que optimizar implica:

- Reducir costos innecesarios
- Mejorar tiempos de ejecución
- Preparar el sistema para crecimiento futuro

En esta sesión se abordan conceptos como:

- Separación de cómputo y almacenamiento
- Uso eficiente de formatos de datos
- Reducción de I/O
- Escalabilidad horizontal implícita en la nube

El objetivo es formar criterio técnico, no micro-optimizar código.

Análisis de decisiones de diseño y optimización

5 Análisis de decisiones de diseño y optimización

¿Por qué se evalúan las decisiones y no solo el resultado?

Porque en la práctica profesional:
- No existe una única solución correcta
- Lo importante es **justificar las decisiones**
- Los trade-offs deben ser explícitos

En esta sesión el estudiante:
- Analiza qué decisiones tomó
- Explica por qué optimizó de cierta forma
- Reconoce limitaciones del diseño actual
- Propone mejoras futuras

Esto prepara al estudiante para:
- Defensas técnicas
- Revisión por pares
- Entrevistas profesionales

BSG Institute

Presentación final del proyecto

6.1 El proyecto como artefacto profesional

La presentación final no es una demostración de código, sino:

- Una **explicación del sistema**
- Una defensa de decisiones técnicas
- Un análisis de rendimiento y escalabilidad

El estudiante debe ser capaz de:

- Explicar el pipeline end-to-end
- Justificar la arquitectura
- Argumentar las optimizaciones realizadas
- Mostrar evidencia de funcionamiento en la nube

Esta presentación simula un **comité técnico real**.

Rol de esta sesión dentro del proyecto final

Rol de esta sesión dentro del proyecto final

Esta sesión cumple un rol fundamental:

- Cierra el ciclo del proyecto final
- Consolida la visión profesional del estudiante
- Distingue ejecución básica de ingeniería real
- Evalúa criterio técnico, no solo implementación

Es la sesión donde:

- Se valida el nivel maestría
- Se observa madurez técnica
- Se integra todo lo aprendido en el curso

Resultado esperado al finalizar la sesión

Al finalizar la Sesión de hoy

Hands on Lab

BSG Institute

Av. Alfredo Benavides 768, Miraflores – Lima
Urb. León XIII Calle 2 Nª 107, Cayma – Arequipa
Carrera 45 #108-27 Torre 1 Oficina 1008 – Bogotá
Av. Marcelo Terceros Bánzer 304 (3er anillo externo) – Santa Cruz
Montecito N° 38, Piso 33 of. 4 Col. Nápoles, World Trade Center – Ciudad de México

www.bsginstitute.com